LAPORAN KEMAJUAN

DEEP LEARNING

DISUSUN OLEH KELOMPOK 2

KETUA/KOORDINATOR:

ARY SIGIT JULIAN (2330105030001)

ANGGOTA:

FEBRIAN NUR HIDAYAT	**(2330105030026)**
NAUFAL FAKHRI	**(2330105030011)**
RAYDAMAR RIZKYAKA RIYADI	**(2330205030035)**
RINALDI RIZWAR	**(2330205030036)**

DOSEN PENGAMPU MATA KULIAH :

NOVERA KRISTIANTI, S.T., M.T.

JURUSAN TEKNIK INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS PALANGKA RAYA

2026

I. PENDAHULUAN

1.1 Latar Belakang

Perkembangan media digital telah mengubah cara masyarakat mengakses informasi. Judul berita menjadi elemen terpenting karena berfungsi sebagai pintu masuk utama yang menentukan apakah pembaca akan mengklik atau mengabaikan suatu berita. Namun, persaingan mendapatkan trafik pengunjung mendorong banyak media *online* menerapkan strategi *clickbait*, yaitu penulisan judul yang berlebihan, menyesatkan, atau memancing rasa penasaran berlebih agar pembaca terdorong mengklik.

Fenomena *clickbait* di Indonesia semakin marak melalui penggunaan kata-kata hiperbolik, penghilangan informasi penting, atau ambiguitas yang sengaja dibuat demi meningkatkan jumlah klik meskipun sering tidak sesuai dengan isi berita. Kondisi ini berpotensi menurunkan kualitas literasi informasi masyarakat dan menyebarkan miskonsepsi.

Oleh karena itu, diperlukan sistem otomatis yang mampu mendeteksi judul berita *clickbait* berbahasa Indonesia. Penelitian ini mengusulkan model klasifikasi menggunakan kombinasi TF-IDF sebagai representasi fitur teks dan *Multi-Layer Perceptron* (MLP) sebagai model klasifikasi. Pendekatan ini dipilih karena relatif ringan secara komputasi dan terbukti efektif pada klasifikasi teks berita berbahasa Indonesia.

1.2 Rumusan Masalah

Berdasarkan latar belakang di atas, rumusan masalah dalam penelitian ini adalah:

1) Bagaimana merancang model klasifikasi judul berita *clickbait* berbahasa Indonesia menggunakan TF-IDF dan *Multi-Layer Perceptron*?
2) Bagaimana performa model MLP + TF-IDF dalam mengklasifikasikan judul berita *clickbait* dan *non-clickbait*?
3) Apa saja keterbatasan model yang diusulkan pada tahap UTS ini?

1.3 Tujuan

Tujuan dari penelitian ini adalah:

1) Membangun model klasifikasi judul berita *clickbait* berbahasa Indonesia menggunakan TF-IDF dan *Multi-Layer Perceptron*.
2) Mengevaluasi performa model berdasarkan metrik *accuracy*, *precision*, *recall*, dan *F1-score*.
3) Menganalisis kelebihan dan keterbatasan model sebagai dasar pengembangan lebih lanjut pada tahap UAS.

II. TINJAUAN PUSTAKA

Clickbait merupakan fenomena penulisan judul berita yang sengaja dirancang untuk menarik perhatian pembaca dengan menciptakan rasa penasaran. Tiara dkk. (2026) menemukan bahwa judul *clickbait* secara konsisten memanfaatkan manipulasi sintaksis, seperti penghilangan elemen penting dan pelanggaran prinsip kerja sama, guna menciptakan celah informasi menyesatkan yang berdampak negatif terhadap literasi informasi pembaca.

Sudianto dkk. (2022) menerapkan TF-IDF dengan algoritma SVM dan MLP untuk klasifikasi topik berita. Hasilnya, MLP mencapai akurasi 78%, sementara SVM mencapai 74%. Mereka menyimpulkan bahwa kedua algoritma tersebut unggul dibandingkan metode lain dan menyarankan pengembangan dengan *Word2Vec* atau *deep learning*.

Alfando dan Hayami (2023) melalui studi literatur menyimpulkan bahwa klasifikasi teks berita berbahasa Indonesia menggunakan *Machine Learning* dan *Deep Learning* efektif untuk prediksi *multi-label*, namun membutuhkan *dataset* yang besar serta pengaturan parameter yang tepat.

Berdasarkan tinjauan tersebut, penelitian ini menggunakan TF-IDF dan *Multi-Layer Perceptron* (MLP) karena terbukti efektif dan relatif ringan secara komputasi untuk klasifikasi judul berita *clickbait*.

III. *DATASET & PREPROCESSING*

3.1 *Dataset*

Dataset yang digunakan adalah "*CLICK-ID: A Novel Dataset for Indonesian Clickbait Headlines*" (William & Sari, 2020) dari *Mendeley Data*, yang berisi 15.000 judul berita dari 12 portal daring hasil anotasi tiga anotator. Dataset terdiri atas *All-Agree* (8.613 data) dan *Does-not-Agree* (6.387 data). Penelitian menggunakan *All-Agree* karena

kesepakatan penuh antar-anotator menghasilkan label yang lebih konsisten. Setelah pembersihan judul kosong, konflik label, dan duplikasi, diperoleh 8.596 data (3.311 *clickbait* dan 5.285 *non-clickbait*), yang dibagi secara *stratified* menjadi *training* 70% (6.016), *validation* 10% (860), dan *testing* 20% (1.720).

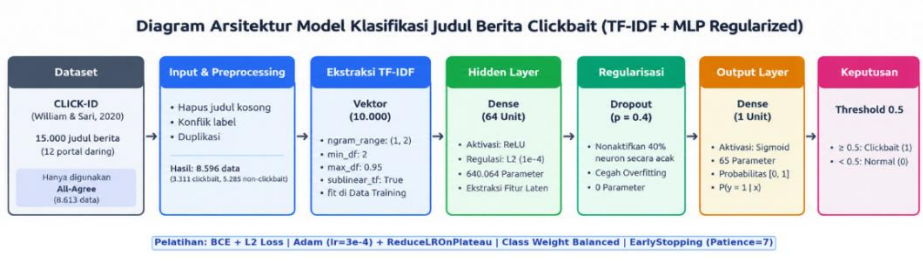
3.2 *Preprocessing* Data

Preprocessing dilakukan dengan pendekatan ringan. Data diambil dari bagian *All-Agree*, lalu diperiksa kelengkapan dan konsistensi labelnya dengan menghapus konflik label serta duplikasi. Seluruh teks diubah menjadi huruf kecil (*case folding*), spasi dinormalisasi, serta karakter khusus dan tanda baca yang tidak diperlukan dibersihkan hingga tersisa 8.596 judul unik. Teks kemudian direpresentasikan menggunakan TF-IDF dengan parameter *max_features*=10.000, *ngram_range*=(1,2), *min_df*=2, *max_df*=0,95, dan *sublinear_tf=True*. TF-IDF hanya di-*fit* pada data *training* untuk menghindari *data leakage*.

IV. METODOLOGI

4.1 Arsitektur Model *Multi-Layer Perceptron* (MLP)

Model klasifikasi yang diusulkan (*build_mlp*) merupakan jaringan syaraf tiruan umpan-maju berjenis *Multi-Layer Perceptron* (MLP) yang menerima masukan berupa vektor *sparse* TF-IDF berdimensi 10.000. Arsitektur dirancang ringkas dengan satu lapisan tersembunyi (10.000 → 64 → 1) berbekal regularisasi penalti bobot L2 dan *Dropout* guna mengompresi fitur leksikal *unigram-bigram* berdimensi tinggi menjadi representasi laten *non-linear* tanpa mengalami *overfitting* (Gambar 1).



Gambar 1. Diagram Arsitektur Model Klasifikasi Judul Berita *Clickbait* (TF-IDF + MLP)

Alur pemrosesan tensor dalam arsitektur jaringan terdiri atas empat komponen berurutan: (a) *Input Layer* penerima vektor fitur TF-IDF berdimensi 10.000, (b) *Hidden Layer* berupa satu lapisan *fully-connected Dense*(64) (640.064 parameter) beraktivasi *ReLU* $f(z) = \max(0, z)$ dengan regularisasi *kernel_regularizer=l2*(1e-4), (c) *Dropout Layer* dengan *Dropout*(0,40) yang menonaktifkan 40% neuron secara acak selama pelatihan guna mencegah ko-adaptasi fitur pada kosakata *sparse*, serta (d) *Output Layer* berupa 1 neuron tunggal *Dense*(1) (65 parameter) beraktivasi *Sigmoid* $\sigma(z) = 1 / (1 + e^{-z})$ yang memetakan *logit* menjadi probabilitas di rentang [0, 1] (ambang keputusan: ≥ 0,50 = *Clickbait* [Kelas 1]; < 0,50 = *Non-Clickbait* [Kelas 0]).

4.2 Fungsi *Loss*, *Optimizer*, dan Konfigurasi *Hyperparameter*

Karena deteksi *clickbait* merupakan tugas klasifikasi biner, fungsi objektif yang diminimalkan adalah kombinasi *Binary Cross-Entropy* (BCE) *Loss* dengan regularisasi penalti bobot L2 (1e-4). Pembaruan bobot dilakukan menggunakan algoritma optimasi Adam dengan laju pembelajaran awal *lr* = 3e-4 (0,0003) berpadu penjadwal *ReduceLROnPlateau*(*monitor*='*val_loss*', *factor*=0,5, *patience*=3, *min_lr*=1e-5) serta pembobotan kelas seimbang *class_weight*='*balanced*' ($w_0 \approx 0{,}813$; $w_1 \approx 1{,}298$). Spesifikasi lengkap lapisan dan *hyperparameter* dirangkum pada Tabel 1.

Tabel 1. Spesifikasi Arsitektur Lapisan dan Konfigurasi *Hyperparameter* Model MLP

Komponen Lapisan	Spesifikasi & *Hyperparameter*	Dimensi atau Nilai	Parameter	Keterangan Fungsional & Justifikasi
input_layer	*Input* Vektor TF-IDF *Unigram-Bigram*	(*None*, 10000)	0	*ngram*=(1,2), *min_df*=2, *max_df*=0,95, *sublinear_tf*
dense_hidden	*Dense*(64, *ReLU*) + *Kernel* L2(1e-4)	(*None*, 64)	640.064	Ekstraksi representasi fitur laten + penalti L2
dropout_layer	*Dropout* (*rate* = 0,40)	(*None*, 64)	0	Nonaktifkan 40% neuron acak (cegah *overfitting*)
output_sigmoid	*Dense*(1, *Sigmoid*)	(*None*, 1)	65	Estimasi probabilitas *Clickbait* [0, 1]
Total Parameter	**Arsitektur MLP**	**10000→64→1**	**640.129**	**640.129 *Trainable* (100%) | 0 *Non-Trainable***

Loss & *Class Weight*	BCE + L2(1e-4) & *Balanced Weight*	w0=0,81; w1=1,30	—	*compute_class_weight*('*balanced*') antarkelas
Optimizer & LR	Adam + *ReduceLROnPlateau*	*lr* awal = 3e-4	—	*factor*=0,5, *patience*=3, *min_lr*=1e-5 (adaptif)
EarlyStopping	*EarlyStopping(monitor='val_loss', patience=7, restore_best_weights=True)*	Maksimum 50 *epoch; patience = 7*	—	Menghentikan pelatihan saat *val_loss* tidak membaik selama 7 *epoch* dan memulihkan bobot terbaik

V. EKSPERIMEN & HASIL

5.1 Tabel Perbandingan Model dan *Classification Report*

Eksperimen evaluasi dilakukan pada data pengujian (*Test Set* sebanyak 1.720 sampel) dengan membandingkan model usulan *Multi-Layer Perceptron* (MLP) terhadap dua model *baseline* pembelajaran mesin klasik, yaitu *Logistic Regression* dan *Naive Bayes*. Hasil perbandingan dan rincian *Classification Report* per kelas disajikan pada Tabel 2.

Tabel 2. Perbandingan Model dan Rincian *Classification Report* MLP (*Test Set n* = 1.720)

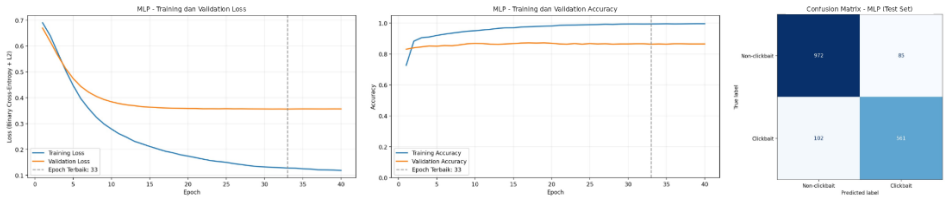
Model / Kelas Evaluasi (*Test Set n* = 1.720)	***Accuracy* (%)**	***Precision* (%)**	***Recall* (%)**	***F1 Clickbait*/Kelas (%)**	***F1 Macro* (%)**
Logistic Regression (*Baseline* 1)	88,37	94,26 (*Clickbait*)	74,36 (*Clickbait*)	83,14	87,13
Naive Bayes (*Baseline* 2)	85,81	89,01 (*Clickbait*)	72,10 (*Clickbait*)	79,67	84,39
MLP (Model Usulan — Utama)	**89,13**	**86,84 (*Clickbait*)**	**84,62 (*Clickbait*)**	**85,71**	**88,47**
MLP — Kelas *Non-clickbait* (*n*=1.057)	—	90,50	91,96	91,22	—
MLP — Kelas *Clickbait* (*n*=663)	—	86,84	84,62	85,71	—
MLP — *Macro Average* (*n*=1.720)	**89,13**	**88,67**	**88,29**	**—**	**88,47**
MLP — *Weighted Average* (*n*=1.720)	**89,13**	**89,09**	**89,13**	**89,10 (*Weighted*)**	**88,47**

Berdasarkan Tabel 2, MLP (Model Usulan) meraih performa terbaik secara keseluruhan dengan *Accuracy* tertinggi 89,13% dan *F1 Macro* tertinggi 88,47%, mengungguli *Logistic Regression* (*Accuracy* 88,37%; *F1 Macro* 87,13%) dan *Naive Bayes* (*Accuracy* 85,81%; *F1 Macro* 84,39%). Keunggulan paling signifikan dari arsitektur MLP terletak pada

peningkatan *Recall Clickbait* yang melonjak menjadi 84,62% (+10,26% di atas *Logistic Regression* 74,36% dan +12,52% di atas *Naive Bayes* 72,10%), sehingga menghasilkan *F1 Clickbait* tertinggi 85,71%.

5.2 Analisis Kurva Pelatihan dan *Confusion Matrix*

Pelatihan jaringan MLP dijalankan selama 40 *epoch* dengan memantau perkembangan *Binary Cross-Entropy* + L2 *Loss*, akurasi pelatihan/validasi, serta evaluasi *Confusion Matrix* pada data uji (1.720 sampel) sebagaimana ditampilkan pada Gambar 2.



Gambar 2. Hasil Eksperimen MLP: (Kiri) Kurva *Training* & *Validation Loss*, (Tengah) Kurva *Accuracy*, serta (Kanan) *Confusion Matrix* pada *Test Set* (n = 1.720)

Berdasarkan kurva pelatihan pada Gambar 2, nilai *Training Loss* menurun tajam dari ~0,69 pada *Epoch* 1 menuju ~0,12 pada *Epoch* 40, sementara *Training Accuracy* meningkat mendekati 99,5%. Model mencapai konvergensi validasi terbaik pada *Epoch* ke-33 dengan *Validation Loss* 0,3565. Berdasarkan *Confusion Matrix* pada Gambar 2 (kanan), dari 1.720 sampel uji (1.057 *Non-clickbait* dan 663 *Clickbait*), model mengklasifikasikan 1.533 judul berita dengan benar (89,13%) dan hanya mengalami kesalahan pada 187 sampel (10,87%), meliputi: (1) *True Negative* (TN) = 972 data (91,96% dari 1.057 *Non-clickbait*); (2) *True Positive* (TP) = 561 data (84,62% dari 663 *Clickbait*); (3) *False Positive* (FP) = 85 data (8,04% dari 1.057 *Non-clickbait*); serta (4) *False Negative* (FN) = 102 data (15,38% dari 663 *Clickbait*).

VI. PEMBAHASAN

6.1 Analisis Kesalahan Prediksi (*Error Analysis*)

Pemeriksaan 187 sampel kesalahan klasifikasi (85 *False Positive* dan 102 *False Negative*) menunjukkan bahwa kesalahan model berakar pada

kemiripan leksikal permukaan antara berita faktual hukum/ekonomi dengan judul *clickbait* serta gaya bahasa *soft-clickbait* implisit (Tabel 3).

Tabel 3. Analisis Contoh Kasus Kesalahan Prediksi (85 *False Positive* dan 102 *False Negative*)

Jenis Galat	Contoh Pola Judul Berita	Aktual → Prediksi	Analisis Penyebab Kesalahan
False Positive (85 data)	"kronologi lengkap kejadian mengejutkan di balik penangkapan tersangka korupsi"	*Non-clickbait* → *Clickbait*	*Bigram* 'kejadian mengejutkan' dan 'di balik' memiliki bobot IDF tinggi pada kelas *clickbait* meskipun isi berita bersifat investigasi faktual.
False Positive (85 data)	"ini alasan bank indonesia tahan suku bunga acuan bulan ini"	*Non-clickbait* → *Clickbait*	Frasa penunjuk 'ini alasan' di awal kalimat diasosiasikan dengan pola *forward-referencing*, padahal konteks kalimat bersifat ekonomi formal.
False Negative (102 data)	"komentar pelatih timnas usai laga semalam bikin publik tanah air geleng kepala"	*Clickbait* → *Non-clickbait*	Mayoritas token ('komentar pelatih', 'timnas', 'usai laga') adalah kosakata olahraga standar yang mendominasi rata-rata bobot TF-IDF.
False Negative (102 data)	"mengintip deretan koleksi mobil mewah milik pejabat daerah yang jarang tersorot"	*Clickbait* → *Non-clickbait*	Judul membangun *curiosity gap* secara halus melalui klausa panjang tanpa kata hiperbolik eksplisit (seperti '*viral*' atau 'tak disangka').

Tiga pola utama pemicu kesalahan tersebut meliputi: (a) Bias Kata Kunci Sensasional pada Berita Faktual (FP = 85), di mana berita *hard news* bermuatan kata sifat emosional atau kata penunjuk langsung memicu aktivasi neuron tinggi pada lapisan tersembunyi pertama; (b) Dominasi Kosakata Formal pada *Soft-Clickbait* (FN = 102), di mana judul dengan 80% kosakata jurnalistik formal memiliki rata-rata vektor TF-IDF condong ke kelas *Non-clickbait*; serta (c) Ketidakseimbangan Proporsi Kelas Moderat (61,48% *Non-clickbait* berbanding 38,52% *Clickbait*), yang menyebabkan *Logistic Regression* dan *Naive Bayes* hanya mencapai *Recall Clickbait* 74,36% dan 72,10% (konservatif), sedangkan MLP mampu mengangkat *Recall Clickbait* hingga 84,62%.

6.2 Keterbatasan Model pada Tahap UTS

Meskipun kombinasi MLP + TF-IDF mencapai akurasi pengujian 89,13% dan *F1 Macro* 88,47%, pendekatan tahap UTS ini memiliki empat keterbatasan mendasar: (a) Hilangnya Konteks Urutan Kalimat (*Loss of Sequential Order*) karena representasi *bag-of-n-grams* TF-IDF tidak

memahami struktur sintaksis sekuensial judul, (b) Ketiadaan Pemahaman Semantik dan Sinonim (*Semantic Blindness*) karena tiap token diperlakukan sebagai dimensi ortogonal terpisah sehingga kata bersinonim ('heboh', 'geger', 'gempar') tidak memiliki kedekatan vektor, (c) Kerentanan terhadap Kosakata Baru (*Out-of-Vocabulary* / OOV) di luar 10.000 fitur data latih, serta (d) Hilangnya Sinyal Tanda Baca Ekspresif (??? atau !) akibat penghapusan karakter khusus pada tahap.

VII. KESIMPULAN & RENCANA LANJUTAN

Kesimpulan Tahap UTS: (a) Model klasifikasi judul berita *clickbait* berbahasa Indonesia berhasil dibangun menggunakan ekstraksi fitur TF-IDF (10.000 fitur *unigram-bigram*) dan *Multi-Layer Perceptron* (MLP) pada 8.596 data bersih *subset All-Agree* CLICK-ID melalui pelatihan 40 *epoch* (konvergensi terbaik *Epoch* 33, *Validation Loss* 0,3565), (b) Evaluasi pada 1.720 data uji membuktikan MLP meraih performa terbaik dengan *Accuracy* 89,13%, *Precision Clickbait* 86,84%, *Recall Clickbait* 84,62%, *F1 Clickbait* 85,71%, dan *F1 Macro* 88,47% (*Weighted F1* 89,10%), mengungguli *Logistic Regression* (*Accuracy* 88,37%; *F1 Macro* 87,13%) dan *Naive Bayes* (*Accuracy* 85,81%; *F1 Macro* 84,39%), serta (c) Evaluasi *Confusion Matrix* mencatat 972 *True Negative* dan 561 *True Positive* (1.533 prediksi benar), dengan sisa kesalahan 85 *False Positive* dan 102 *False Negative* akibat keterbatasan TF-IDF dalam menangkap urutan sekuensial dan semantik kalimat.

Rencana Lanjutan Tahap UAS: (a) Mengimplementasikan arsitektur sekuensial *Long Short-Term Memory* (LSTM / *Bidirectional* LSTM) guna memodelkan urutan kata dan ketergantungan konteks jarak jauh, (b) Menggantikan vektor *sparse* TF-IDF dengan representasi padat *Word Embedding* (*Word2Vec* / *FastText* Bahasa Indonesia) untuk mengatasi masalah sinonim dan OOV, (c) Menerapkan *class weighting* pada fungsi *loss* serta mempertahankan tanda baca ekspresif (? dan !), serta (d) Melakukan studi komparatif menyeluruh antara performa MLP + TF-IDF (Tahap UTS) dan LSTM + *Word Embedding* (Tahap UAS).

DAFTAR PUSTAKA

Alfando, & Hayami, R. (2023). Klasifikasi Teks Berita Berbahasa Indonesia Menggunakan *Machine Learning* dan *Deep Learning*: Studi Literatur. *Jurnal Teknologi Informasi dan Ilmu Komputer*.

Pardede, D., Hayadi, B. H., & Iskandar. (2022). Kajian Literatur *Multi Layer Perceptron*: Seberapa Baik Performa Algoritma Ini. *Journal of ICT Application and System*, *1*(1), 23–34.

Sudianto, dkk. (2022). Penerapan Algoritma *Support Vector Machine* dan *Multi-Layer Perceptron* pada Klasifikasi Topik Berita. *JANAPATI*, *11*(2), 84–91. https://doi.org/10.23887/janapati.v11i2.44151

Tiara, Sintasari, D. P., & Miftakhuddin. (2026). Analisis Linguistik Judul Berita *Clickbait* dan Dampaknya terhadap Literasi Informasi. *Jurnal BASTRA*, *11*(3), 1103–1109.

William, A., & Sari, Y. (2020). *CLICK-ID: A Novel Dataset for Indonesian Clickbait Headlines*. *Mendeley Data*, V1. https://data.mendeley.com/datasets/k42j7x2kpn

LAMPIRAN

Lampiran 1. Tabel Pembagian Tugas

No	Nama Mahasiswa	NIM	Peran	Detail
1	Ary Sigit Julian	2330105030001	Ketua (koordinator), evaluator, penulis laporan	Bertugas mengatur jalannya kerja kelompok. Selain itu juga menjadi evaluator pada hasil training model, membuat laporan bagian pendahuluan, tinjauan pustaka, serta dataset & preprocessing.
2	Febrian Nur Hidayat	2330105030026	Data engineer, model engineer, evaluator, penulis laporan	Bertugas mencari dataset yang akan digunakan, membuat model training LR, NB, TF-IDF, dan MLP, membandingkan hasil antar model, membantu laporan bagian eksperimen & hasil, serta mengunggah data project pada repository.
3	Naufal Fakhri	2330105030011	Data engineer, model engineer, evaluator, penulis laporan	Bertugas membersihkan dataset yang telah dipilih, membuat kode untuk cleaning data, mengevaluasi hasil cleaning data, membantu laporan bagian dataset & preprocessing, dan membuat repository untuk penyimpanan data project pada GitHub.
4	Raydamar Rizkyaka Riyadi	2330205030035	Model engineer, penulis laporan, pembuat PPT	Bertugas menentukan LR dan NB sebagai pembanding model, membuat laporan bagian metodologi, eksperimen & hasil, pembahasan, kesimpulan & rencana lanjutan, serta

				membuat file README.md pada repository.
5	Rinaldi Rizwar	2330205030036	Model engineer, evaluator, pembuat PPT	Bertugas membantu pengerjaan kode untuk cleaning dan model testing, menjadi evaluator pada hasil cleaning dan training model, serta membuat PPT presentasi kelompok.

Lampiran 2. Link *Repository* GitHub:

https://github.com/nfakhrii/kelompok2-deeplearning